Análise de Repositórios Populares no GitHub: Características e Padrões

Grupo 01:
Nataniel Geraldo Mendes Peixoto
Nelson de Campos Nolasco
Rubia Coelho de Matos

1. Introdução e Hipóteses Iniciais

Este estudo investiga as características dos 100 repositórios mais populares do GitHub para entender os padrões que os tornam bem-sucedidos. Para tanto, foram formuladas as seguintes hipóteses:

H1 (Maturidade): Repositórios populares são relativamente jovens (2-4 anos), pois tecnologias mais recentes tendem a atrair mais atenção.

H2 (Contribuições): Espera-se uma mediana de 200-300 *Pull Requests* (PRs) aceitos, indicando uma comunidade ativa, mas não necessariamente gigante.

H3 (Releases): Projetos populares devem ter lançamentos moderados (10-20 releases), priorizando estabilidade sobre atualizações frequentes.

H4 (Atualização): A última atualização deve ser recente (<15 dias), demonstrando manutenção ativa.

H5 (Linguagens): JavaScript e TypeScript devem dominar, dado o crescimento do desenvolvimento web.

H6 (Issues): Taxa de resolução de issues deve ser moderada (60-70%), balanceando velocidade e qualidade.

2. Metodologia

Coleta de Dados

- Utilização da API GraphQL do GitHub
- Amostra: 100 repositórios mais estrelados
- Métricas coletadas:
    - Data de criação
    - Número de PRs merged
    - Contagem de releases
    - Data da última atualização
    - Linguagem principal
    - Issues (total e fechadas)

Processamento

- Cálculo de idade em anos
- Normalização de datas para escala internacional de tempo *Coordinated Universal Time* (UTC)
- Cálculo de razão de issues fechadas
- Agregação por linguagem
- Destaca-se que, para a Sprint 01, foi utilizado o arquivo fonte “RepoPop100.py”.

3. Resultados

RQ1: Maturidade dos Sistemas
Hipótese: 2-4 anos
Resultado: Mediana de 8.89 anos
Análise: Hipótese refutada. Sistemas populares são mais maduros que o esperado, sugerindo que a construção de uma base sólida de usuários leva mais tempo.

RQ2: Contribuições Externas
Hipótese: 200-300 PRs
Resultado: Mediana de 1606 PRs
Análise: Hipótese refutada. O volume de contribuições é significativamente maior, indicando comunidades mais ativas que o previsto.

RQ3: Frequência de Releases
Hipótese: 10-20 releases
Resultado: Mediana de 20.50 releases
Análise: Hipótese parcialmente refutada. Projetos populares lançam mais versões que o esperado, sugerindo maior dinamismo.

RQ4: Atualização dos Sistemas
Hipótese: <15 dias
Resultado: Mediana de 0.01 dias
Análise: Hipótese confirmada. Projetos populares são mantidos muito ativamente.

RQ5: Linguagens Dominantes
Hipótese: JavaScript/TypeScript dominantes
Resultado: Top 5:

1. TypeScript (22%)
2. Python (20%)
3. JavaScript (19%)
4. C++ (9%)
5. Go (8%)

Análise: Hipótese parcialmente confirmada. TypeScript lidera, mas Python tem presença mais forte que o esperado.

RQ6: Resolução de Issues
Hipótese: 60-70% de resolução
Resultado: Mediana de 87.61%
Análise: Hipótese refutada. A taxa de resolução é significativamente maior, indicando maior eficiência na manutenção.

4. Discussão

Descobertas Principais

1. **Maturidade Importa**: A popularidade está mais ligada à maturidade do que à novidade.
2. **Comunidades Mais Ativas**: O volume de contribuições é substancialmente maior que o esperado, indicando comunidades mais engajadas.
3. **Manutenção Intensiva**: Alta frequência de releases e atualizações constantes são características marcantes.
4. **Diversidade Técnica**: Embora JavaScript lidere, existe uma distribuição mais equilibrada entre diferentes linguagens.
5. **Eficiência Operacional**: A alta taxa de resolução de issues sugere processos bem estabelecidos de manutenção.

Limitações do Estudo

1. Viés de Seleção: Foco apenas nos repositórios mais populares pode não representar o ecossistema completo.
2. Momento Único: Análise pontual não captura tendências temporais.
3. Métricas Limitadas: Não considera aspectos qualitativos como qualidade do código ou documentação.

Implicações Práticas

1. **Para Mantenedores**:
    - Priorizar resolução rápida de issues
    - Manter ritmo constante de releases
    - Investir em construção de comunidade
2. **Para Contribuidores**:
    - Projetos maduros oferecem mais oportunidades de contribuição
    - Alta taxa de PRs sugere boa receptividade a contribuições
3. **Para Usuários**:
    - Maturidade do projeto pode ser indicador de estabilidade
    - Alta taxa de resolução de issues indica suporte ativo

Trabalhos Futuros

1. Análise longitudinal para identificar tendências ao longo do tempo
2. Inclusão de métricas qualitativas
3. Estudo comparativo com repositórios menos populares
4. Investigação de fatores que influenciam o crescimento da popularidade

Esta análise revela que projetos de código aberto bem-sucedidos exigem mais maturidade e manutenção ativa do que inicialmente previsto, com comunidades mais engajadas e processos mais eficientes do que as hipóteses iniciais sugeriam.

Anexo

RESULTADOS DA PESQUISA:

RQ 01. Sistemas populares são maduros/antigos?

Idade média dos repositórios: 8.72 anos

Mediana da idade: 8.89 anos

RQ 02. Sistemas populares recebem muita contribuição externa?

Média de PRs aceitas: 6365.00

Mediana de PRs aceitas: 1606.00

A diferença observada entre os valores da média e mediana pode ser explicada pelos *outliers* presentes na amostra, tal como evidenciado no gráfico abaixo:

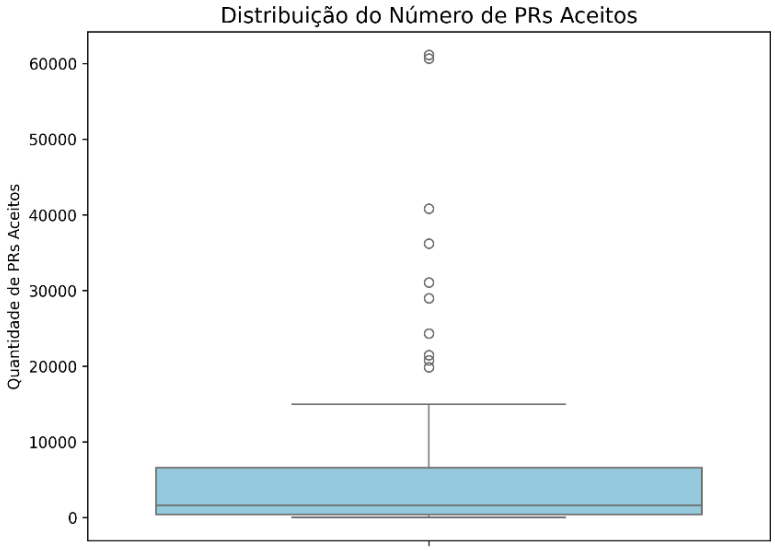

RQ 03. Sistemas populares lançam releases com frequência?

Média de releases: 131.73

Mediana de releases: 20.50

RQ 04. Sistemas populares são atualizados com frequência?

Média de dias desde última atualização: 0.03

Mediana de dias desde última atualização: 0.01

RQ 05. Sistemas populares são escritos nas linguagens mais populares?

Top 10 linguagens mais usadas nos repositórios populares (após limpados os “none”):

TypeScript	16
Python	15
JavaScript	14
C++	7
Go	6
Rust	4
Shell	4
Java	3
Jupyter Notebook	2

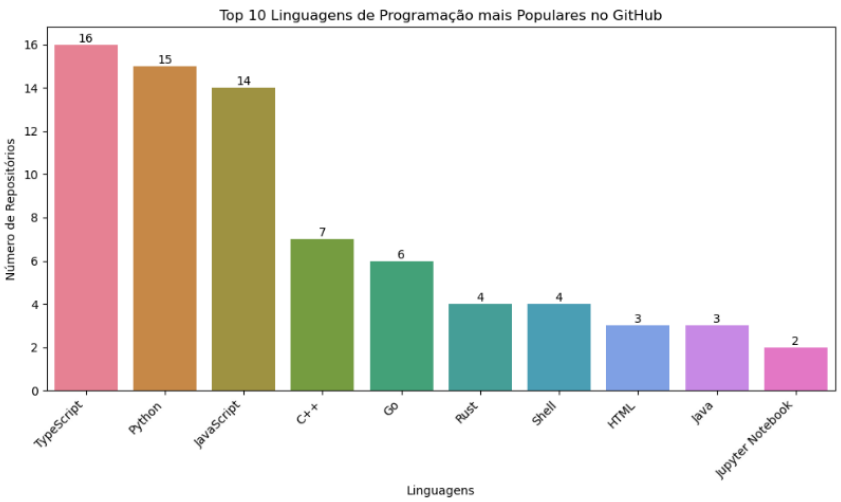

RQ 06. Sistemas populares possuem um alto percentual de issues fechadas?

Média do percentual de issues fechadas: 76.03%

Mediana do percentual de issues fechadas: 87.61%

RQ 07. Análise por linguagem das principais métricas:

Média de métricas por linguagem popular:

Language	Pull Requests	Releases	days_since_update
C++	17026.71	270.29	0.03
Go	11288.50	160.33	0.02
HTML	3195.00	0.00	0.01
Java	1158.33	3.00	0.10
JavaScript	5839.21	168.36	0.04
Jupyter Notebook	6583.50	399.50	0.03
Python	3149.67	67.67	0.01
Rust	20386.25	367.75	0.01
Shell	1234.25	65.50	0.03
TypeScript	8576.75	256.88	0.05

Dados salvos em 'github_analysis.csv'